



Министерство науки и высшего образования Российской Федерации
федеральное государственное бюджетное образовательное
учреждение высшего профессионального образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)» (МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Робототехника и комплексная автоматизация»
КАФЕДРА «Системы автоматизированного проектирования (РК-6)»

РАСЧЁТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к научно-исследовательской работе студента

на тему

«Прогностическая способность глобальных нейросетевых моделей в
случае нестационарных временных рядов»

Студент РК6-76Б
группа

подпись, дата

Новокшанов Е.А.
ФИО

Руководитель НИРС

подпись, дата

Соколов А.П.
ФИО

Консультант

подпись, дата

Першин А.Ю.
ФИО

Москва, 2023

РЕФЕРАТ

научно-исследовательская работа студента: 8 с., 0 рис., 0 табл., 10 источн.

.

Работа посвящена обзору литературы в рамках исследования прогностической способности глобальных нейросетевых моделей в случае нестационарных временных рядов. В качестве объекта исследования были выбрана модель DLinear и метод обучения rolling window. В связи с этим был проведен обзор статей, в которых проводится анализ и сравнения эффективности применения данного типа моделей для прогнозирования нестационарных временных рядов.

Тип работы: научно-исследовательская работа студента.

Тема работы: *«Прогностическая способность глобальных нейросетевых моделей в случае нестационарных временных рядов».*

Объект исследования: Простые трансформеры и их применения в задачах прогнозирования нестационарных временных рядов.

Основная задача, на решение которой направлена работа: Исследование современных методов прогнозирования нестационарных временных рядов и проведение анализа их эффективности.

Цели работы: поиск источников литературы, обзор, определение объекта исследования и перспективы развития

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
Выводы	5
Литература	6

ВВЕДЕНИЕ

В современном мире объемы данных, генерируемых компьютерными системами, растут с каждым днем. Одной из задач, которые возникают перед исследователями и аналитиками данных, является прогнозирование значений временных рядов. Временные ряды широко применяются в финансовой аналитике, климатологии, экономике и других областях.

Однако прогнозирование временных рядов является нетривиальной задачей, особенно в случае нестационарных временных рядов. Нестационарность означает, что свойства ряда, такие как среднее значение и дисперсия, меняются со временем. Использование традиционных статистических методов, таких как ARIMA, может быть неэффективным в таких случаях.

В последние годы нейросетевые модели показали свою эффективность в прогнозировании временных рядов. Основное преимущество нейросетевых моделей состоит в их способности автоматически извлекать сложные зависимости в данных. Глобальные нейросетевые модели, такие как рекуррентные нейронные сети (RNN) и сверточные нейронные сети (CNN), позволяют учитывать долгосрочные зависимости в данных.

Однако последние исследования [1] говорят о том, что классические модели ML(machine learning) и DL(deep learning), а так же их ансамбли, во многих случаях справляются с задачей прогнозирования нестационарных временных рядов хуже статистических моделей. Для предсказания значений временного ряда было предложено [2] использовать трансформеры, которые раньше использовались только в задачах NLP(Natural Language Processing).

На основе обзора литературы статей [3], [4], [1], [5], [2], [6], [7], [8], [9] и [10], объектом исследования были выбраны простейшие однослойные трансформеры и их применения в задачах прогнозирования нестационарных временных рядов.

Выводы

В данном обзоре литературы были рассмотрены различные модели трансформеров и других моделей ML и DL, а также их эффективность в контексте задач предсказания временных рядов. Был проведен анализ работы модели DLinear и метода скользящего окна. Также был проведен обзор литературы, рассматривающей нестационарные временные ряды и их свойства.

Был проведен анализ различных глобальных нейросетевых моделей, таких как Recurrent Neural Network(RNN) [4], Long Short-Term Memory (LSTM), Gated Recurrent Unit (GRU) и другие. Было показано, что эти модели успешно применяются для анализа стационарных временных рядов, но не всегда справляются с нестационарными данными.

Тем не менее, вопрос об отставании глобальных нейросетевых моделей от статистических методов требует более детального рассмотрения. В ряде случаев, статистические методы могут проявлять себя эффективно. Однако, именно адаптация и обучение на больших объемах данных при использовании нейросетей могут привести к лучшей способности моделей обрабатывать сложные, нелинейные и нестационарные зависимости.

Также было выявлено, что даже простые модели трансформеров могут хорошо себя показывать при прогнозировании нестационарных временных рядов.

Поэтому применение трансформеров в случае нестационарных временных рядов остается открытой проблемой. Дальнейшие исследования должны быть направлены на разработку более эффективных методов анализа и прогнозирования нестационарных данных.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1 Spyros Makridakis Evangelos Spiliotis Vassilios Assimakopoulos Artemios-Anargyros Semenoglou Gary Mulder, Nikolopoulos Konstantinos. Statistical, machine learning and deep learning forecasting methods: Comparisons and ways forward // Journal of the Operational Research Society. 2023. T. 74, № 3. C. 840–859. URL: <https://doi.org/10.1080/01605682.2022.2118629>.
- 2 Ailing Zeng Muxi Chen Lei Zhang Qiang Xu. Are Transformers Effective for Time Series Forecasting? // Cornell University. 2022. URL: <https://doi.org/10.48550/arXiv.2205.13504>.
- 3 Haixu Wu Jiehui Xu Jianmin Wang Mingsheng Long. Autoformer: Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting // Cornell University. 2021. URL: <https://doi.org/10.48550/arXiv.2106.13008>.
- 4 Bandara Kasun, Bergmeir Christoph, Smyl Slawek. Forecasting across time series databases using recurrent neural networks on groups of similar series: A clustering approach // Expert Systems with Applications. 2020. T. 140. C. 112896. URL: <https://www.sciencedirect.com/science/article/pii/S0957417419306128>.
- 5 Hewamalage H. Ackermann K. Bergmeir C. Forecast evaluation for data scientists: common pitfalls and best practices. // Data Mining and Knowledge Discovery. 2023. T. 37. C. 788–832. URL: <https://doi.org/10.1007/s10618-022-00894-5>.
- 6 Tian Zhou Ziqing Ma Qingsong Wen Xue Wang Liang Sun Rong Jin. FEDformer: Frequency Enhanced Decomposed Transformer for Long-term Series Forecasting // Cornell University. 2022. URL: <https://doi.org/10.48550/arXiv.2201.12740>.
- 7 Zhe Li Shiyi Qi Yiduo Li Zenglin Xu. Revisiting Long-term Time Series Forecasting: An Investigation on Linear Mapping // Cornell University. 2023. URL: <https://doi.org/10.48550/arXiv.2305.10721>.
- 8 Wei Li Xiangxu Meng Chuhao Chen Jianing Chen. Mlinear: Rethink the Linear Model for Time-series Forecasting // Cornell University. 2023. URL:

<https://doi.org/10.48550/arXiv.2305.04800>.

9 Ronghao Ni Zinan Lin Shuaiqi Wang Giulia Fanti. Mixture-of-Linear-Experts for Long-term Time Series Forecasting // Cornell University. 2023. URL: <https://doi.org/10.48550/arXiv.2312.06786>.

10 Zhang G.Peter, Qi Min. Neural network forecasting for seasonal and trend time series // European Journal of Operational Research. 2005. Т. 160, № 2. С. 501–514. Decision Support Systems in the Internet Age. URL: <https://www.sciencedirect.com/science/article/pii/S0377221703005484>.

Выходные данные

Новокишанов Е.А.. Прогностическая способность глобальных нейросетевых моделей в случае нестационарных временных рядов по дисциплине «Модели и методы анализа проектных решений». [Электронный ресурс] — Москва: 2023. — 8 с. URL: <https://sa2systems.ru:88/rnd/rndtsa> (система контроля версий кафедры РК6)

Постановка:



Доцент, к.ф.-м.н., Соколов А.П.

Решение и вёрстка:



студент группы РК6-76Б, Новокишанов Е.А.

2023, осенний семестр